



«Εφαρμογές Τεχνητής Νοημοσύνης»

Ταξινόμηση Σωματικών και Κληρονομικών Μεταλλάξεων DNA Αποκλειστικά από το Τοπικό Ακολουθιακό Περιβάλλον

Στέλλα Χαντάβα (mtn2528)

22 Ιουνίου 2026

Περίληψη

Η παρούσα εργασία εξετάζει την ταξινόμηση μεταλλάξεων DNA σε σωματικές (somatic) και κληρονομικές (germline) με χρήση τεχνικών Τεχνητής Νοημοσύνης. Δημιουργήθηκε ισορροπημένο σύνολο δεδομένων από δημόσιες βάσεις γονιδιωματικών παραλλαγών, αποτελούμενο από 10.000 σωματικές και 10.000 κληρονομικές μεταλλάξεις τύπου Single Nucleotide Variant. Για κάθε μετάλλαξη εξήχθη μεταλλαγμένη ακολουθία μήκους 201 βάσεων, με τη θέση της μετάλλαξης στο κέντρο.

Στο πλαίσιο της εργασίας αξιολογήθηκαν διαφορετικές προσεγγίσεις μηχανικής μάθησης και βαθιάς μάθησης για την ταξινόμηση μεταλλάξεων DNA. Εκτός από κλασικές μέθοδοι μηχανικής μάθησης, όπως Logistic Regression και XGBoost με χαρακτηριστικά k-mer, καθώς και ένα μονοδιάστατο συνελκτικό νευρωνικό δίκτυο., εξετάστηκε και η αξιοποίηση του προεκπαιδευμένου μοντέλου Nucleotide Transformer ως εξαγωγέα αναπαραστάσεων (embeddings).

Παράλληλα, δημιουργήθηκε ένα σύνολο ερμηνεύσιμων βιολογικών χαρακτηριστικών, όπως η περιεκτικότητα GC, το πλήθος θέσεων CpG, ο τύπος μετάλλαξης και το τοπικό περιβάλλον γύρω από τη μεταλλαγμένη θέση. Τέλος, διερευνήθηκε ένας συνδυασμός των δύο προσεγγίσεων μέσω ενός υβριδικού μοντέλου που αξιοποιεί τόσο τις αναπαραστάσεις του Nucleotide Transformer όσο και τα βιολογικά χαρακτηριστικά.

1 Εισαγωγή

Οι γενετικές μεταλλάξεις μπορούν να διακριθούν σε κληρονομικές (germline) και σωματικές (somatic). Οι κληρονομικές μεταλλάξεις μεταβιβάζονται από γενιά σε γενιά και υπάρχουν σε όλα τα κύτταρα ενός οργανισμού, ενώ οι σωματικές εμφανίζονται κατά τη διάρκεια της ζωής του και συνήθως περιορίζονται σε συγκεκριμένους ιστούς. Η διάκριση των δύο κατηγοριών είναι ιδιαίτερα σημαντική στη μελέτη του καρκίνου και στη σύγχρονη γονιδιωματική ανάλυση.

Τα τελευταία χρόνια η Τεχνητή Νοημοσύνη έχει χρησιμοποιηθεί με επιτυχία σε πληθώρα βιοπληροφορικών προβλημάτων, όπως η ανάλυση ακολουθιών DNA, η πρόβλεψη λειτουργικών περιοχών του γονιδιώματος και η μελέτη γενετικών παραλλαγών. Παράλληλα, η εμφάνιση μεγάλων προεκπαιδευμένων μοντέλων για γονιδιωματικές ακολουθίες, όπως το Nucleotide Transformer, δημιούργησε νέες δυνατότητες αξιοποίησης της αναπαραστατικής μάθησης στον χώρο της γονιδιωματικής.

Σκοπός της παρούσας εργασίας είναι να διερευνηθεί κατά πόσο διαφορετικές τεχνικές μηχανικής μάθησης και βαθιάς μάθησης μπορούν να διαχωρίσουν σωματικές και κληρονομικές μεταλλάξεις χρησιμοποιώντας αποκλειστικά πληροφορία από την τοπική ακολουθία DNA γύρω από τη θέση της μετάλλαξης. Για τον σκοπό αυτό αξιολογούνται κλασικά μοντέλα βασισμένα σε k-mer χαρακτηριστικά, συνελικτικά νευρωνικά δίκτυα, προεκπαιδευμένα γονιδιωματικά μοντέλα και συνδυασμοί αυτών με βιολογικά εμπνευσμένα χαρακτηριστικά.

2 Περιγραφή Προβλήματος

Η εργασία αντιμετωπίζει το πρόβλημα ως πρόβλημα δυαδικής ταξινόμησης. Για κάθε μετάλλαξη παρέχεται μία μεταλλαγμένη ακολουθία DNA μήκους 201 βάσεων, στην οποία η μεταλλαγμένη θέση βρίσκεται στο κέντρο της ακολουθίας. Στόχος είναι η πρόβλεψη της κατηγορίας της μετάλλαξης ως σωματικής (somatic) ή κληρονομικής (germline).

Η βασική υπόθεση είναι ότι το τοπικό περιβάλλον γύρω από μία μετάλλαξη ενδέχεται να περιέχει χρήσιμες πληροφορίες σχετικά με την προέλευσή της. Χαρακτηριστικά όπως συγκεκριμένα μοτίβα βάσεων, περιοχές πλούσιες σε GC, θέσεις CpG ή συγκεκριμένοι τύποι αντικατάστασης νουκλεοτιδίων είναι πιθανό να σχετίζονται με διαφορετικούς μηχανισμούς δημιουργίας μεταλλάξεων.

Για να διερευνηθεί η πληροφορία που περιέχεται στις ακολουθίες, αξιολογήθηκαν διαφορετικές κατηγορίες μοντέλων Τεχνητής Νοημοσύνης, από κλασικές μεθόδους μηχανικής μάθησης μέχρι σύγχρονα προεκπαιδευμένα μοντέλα γονιδιωματικών ακολουθιών. Επιπλέον εξετάστηκε αν η προσθήκη ερμηνεύσιμων βιολογικών χαρακτηριστικών μπορεί να βελτιώσει την απόδοση των μοντέλων που βασίζονται σε αναπαραστάσεις (embeddings) προερχόμενες από foundation models.

3 Θεωρητικό Υπόβαθρο

3.1 Ακολουθίες DNA ως Γλώσσα

Τα τελευταία χρόνια έχει αναπτυχθεί η ιδέα ότι οι ακολουθίες DNA μπορούν να αντιμετωπιστούν με παρόμοιο τρόπο με τα φυσικά κείμενα. Όπως μία πρόταση αποτελείται από λέξεις με συγκεκριμένη σειρά και συμφραζόμενα, έτσι και μία ακολουθία DNA αποτελείται από νουκλεοτίδια των οποίων η θέση και το τοπικό περιβάλλον μεταφέρουν βιολογική πληροφορία [1].

Η προσέγγιση αυτή οδήγησε στην προσαρμογή τεχνικών της Επεξεργασίας Φυσικής Γλώσσας (Natural Language Processing) στον χώρο της γονιδιωματικής, επιτρέποντας την εκμάθηση αναπαραστάσεων που περιγράφουν μοτίβα και σχέσεις μέσα στις ακολουθίες DNA.

3.2 Foundation Models για Γονιδιωματικές Ακολουθίες

Με βάση την παραπάνω ιδέα αναπτύχθηκαν εξειδικευμένα μοντέλα τύπου Τρανσφορμερ για γονιδιωματικά δεδομένα. Το DNABERT αποτέλεσε μία από τις πρώτες επιτυχημένες εφαρμογές της αρχιτεκτονικής BEPT σε ακολουθίες DNA [2]. Στη συνέχεια προτάθηκε το DNABERT-2, το οποίο βελτίωσε σημαντικά την αποδοτικότητα και τη δυνατότητα γενίκευσης σε πολλαπλά είδη οργανισμών [3].

Πιο πρόσφατα, το Nucleotide Transformer εκπαιδεύτηκε σε εξαιρετικά μεγάλης κλίμακας γονιδιωματικά δεδομένα και έδειξε ότι μπορεί να μάθει γενικευμένες αναπαραστάσεις βιολογικά σημαντικών προτύπων μέσα στις ακολουθίες DNA [4]. Οι αναπαραστάσεις αυτές, γνωστές ως embeddings, μπορούν να χρησιμοποιηθούν ως είσοδος σε μοντέλα ταξινόμησης χωρίς να απαιτείται εκπαίδευση του ίδιου του foundation model από την αρχή.

3.3 Ταξινόμηση Σωματικών και Κληρονομικών Μεταλλάξεων

Η διάκριση μεταξύ σωματικών και κληρονομικών μεταλλάξεων αποτελεί ενεργό ερευνητικό πεδίο, ιδιαίτερα σε περιπτώσεις όπου δεν υπάρχει διαθέσιμο φυσιολογικό δείγμα αναφοράς. Οι Sun et al. [5] έδειξαν ότι είναι δυνατή η διάκριση των δύο κατηγοριών μέσω υπολογιστικών προσεγγίσεων που αξιοποιούν χαρακτηριστικά των μεταλλάξεων και του τοπικού γονιδιωματικού περιβάλλοντος.

Η παρούσα εργασία ακολουθεί μία διαφορετική προσέγγιση, εξετάζοντας κατά πόσο η πληροφορία που περιέχεται αποκλειστικά στην τοπική ακολουθία DNA μπορεί να αξιοποιηθεί για τη συγκεκριμένη ταξινόμηση.

3.4 Ερμηνευσιμότητα και Νευρο-Συμβολικές Προσεγγίσεις

Παρότι τα μοντέλα βαθιάς μάθησης επιτυγχάνουν συχνά υψηλή ακρίβεια, η λειτουργία τους παραμένει δύσκολα ερμηνεύσιμη. Στον χώρο της γονιδιωματικής η ανάγκη κατανόησης των προβλέψεων είναι ιδιαίτερα σημαντική, καθώς οι αποφάσεις σχετίζονται με βιολογικά και ιατρικά συμπεράσματα [6].


Για τον λόγο αυτό έχουν προταθεί προσεγγίσεις που συνδυάζουν αναπαραστάσεις βαθιάς μάθησης με πιο ερμηνεύσιμα χαρακτηριστικά ή μηχανισμούς λογικής συλλογιστικής [7]. Πρόσφατα οι Huynh et al. [8] πρότειναν το πλαίσιο DEFT, το οποίο δημιουργεί δυναμικά χαρακτηριστικά ακολουθίας κατά τη διαδικασία κατασκευής ενός δέντρου αποφάσεων, με στόχο τη βελτίωση της ερμηνευσιμότητας.

Στην παρούσα εργασία η ιδέα αυτή χρησιμοποιείται ως πηγή έμπνευσης για την κατασκευή ερμηνεύσιμων βιολογικών χαρακτηριστικών και την ανάπτυξη ενός υβριδικού μοντέλου που συνδυάζει embeddings από foundation model με βιολογικά χαρακτηριστικά υψηλής ερμηνευσιμότητας.

3.5 Υβριδικά Νευρο-Συμβολικά Συστήματα

Παρότι τα μοντέλα βαθιάς μάθησης μπορούν να εξάγουν πολύπλοκα πρότυπα από τις ακολουθίες DNA, συχνά δυσκολεύονται να ενσωματώσουν ρητή βιολογική γνώση. Για τον λόγο αυτό έχουν προταθεί υβριδικές προσεγγίσεις που συνδυάζουν νευρωνικά δίκτυα με συμβολικούς μηχανισμούς λογικής συλλογιστικής (reasoning).

Σε ένα τέτοιο πλαίσιο, το μοντέλο Τεχνητής Νοημοσύνης παράγει μία αρχική πρόβλεψη βασισμένη στα δεδομένα, ενώ ένα δεύτερο επίπεδο κανόνων αξιολογεί την πρόβλεψη αξιοποιώντας εξωτερική γνώση από βιολογικές βάσεις δεδομένων ή στατιστικά κριτήρια. Η προσέγγιση αυτή βελτιώνει την ερμηνευσιμότητα των αποτελεσμάτων και επιτρέπει την παροχή βιολογικά τεκμηριωμένων εξηγήσεων.



Σχήμα 1: Αρχιτεκτονική του υβριδικού μοντέλου ταξινόμησης. Η μεταλλαγμένη ακολουθία DNA μετατρέπεται σε embeddings μέσω του προεκπαιδευμένου Nucleotide Transformer, τα οποία συνδυάζονται με ερμηνεύσιμα βιολογικά χαρακτηριστικά και χρησιμοποιούνται από ταξινομητή XGBoost.

4 Μεθοδολογία

4.1 Συλλογή και Προεπεξεργασία Δεδομένων

Για τη δημιουργία του συνόλου δεδομένων χρησιμοποιήθηκαν δύο δημόσιες γονιδιωματικές βάσεις δεδομένων. Οι σωματικές μεταλλάξεις προήλθαν από τη βάση COSMIC (Catalogue Of Somatic Mutations In Cancer), ενώ οι κληρονομικές μεταλλάξεις προήλθαν από τη βάση ClinVar.

Διατηρήθηκαν αποκλειστικά μεταλλάξεις τύπου Single Nucleotide Variant (SNV). Όλες οι μεταλλάξεις χαρτογραφήθηκαν στο ανθρώπινο γονιδίωμα αναφοράς GRCh38 και πραγματοποιήθηκε έλεγχος συνέπειας του αλληλομόρφου αναφοράς με βάση την αντίστοιχη γονιδιωματική θέση.

Για κάθε μετάλλαξη εξήχθη μία μεταλλαγμένη ακολουθία μήκους 201 βάσεων, με τη μεταλλαγμένη θέση να βρίσκεται ακριβώς στο κέντρο της ακολουθίας. Σε αντίθεση με προσεγγίσεις που χρησιμοποιούν τόσο τη φυσιολογική όσο και τη μεταλλαγμένη ακολουθία, στην παρούσα εργασία χρησιμοποιήθηκε αποκλειστικά η μεταλλαγμένη ακολουθία ως είσοδος των μοντέλων.

Μετά τον καθαρισμό και την ενοποίηση των δεδομένων δημιουργήθηκε ισορροπημένο σύνολο αποτελούμενο από 10.000 σωματικές και 10.000 κληρονομικές μεταλλάξεις. Στη συνέχεια πραγματοποιήθηκε διαχωρισμός σε σύνολο εκπαίδευσης (12.000 μεταλλάξεις), σύνολο επικύρωσης (4.000 μεταλλάξεις) και σύνολο ελέγχου (4.000 μεταλλάξεις).

4.2 Βιολογικό Επίπεδο Χαρακτηριστικών (Biological Reasoning Layer)

Παράλληλα με τις ακατέργαστες ακολουθίες DNA δημιουργήθηκε ένα σύνολο βιολογικά ερμηνεύσιμων χαρακτηριστικών με στόχο την περιγραφή του τοπικού περιβάλλοντος της μετάλλαξης.

Τα χαρακτηριστικά αυτά περιλάμβαναν:

- Τον τύπο της μετάλλαξης (π.χ. A→G, C→T).
- Τη διάκριση μεταξύ μεταβάσεων (transitions) και μετατροπών (transversions).
- Το τοπικό περιβάλλον 3, 5 και 7 νουκλεοτιδίων γύρω από τη μεταλλαγμένη θέση.
- Την παρουσία ή απουσία θέσης CpG στο κέντρο της ακολουθίας.

- Την περιεκτικότητα GC σε ολόκληρη την ακολουθία καθώς και σε τοπικά παράθυρα 21 και 41 βάσεων γύρω από τη μετάλλαξη.
- Τη διαφορά μεταξύ τοπικής και συνολικής περιεκτικότητας GC.
- Το πλήθος εμφανίσεων μοτίβων CpG τόσο συνολικά όσο και τοπικά.
- Το μήκος του μεγαλύτερου ομοπολυμερούς τμήματος (homopolymer run).
- Τη συχνότητα επαναλαμβανόμενων μοτίβων όπως AAAA, TTTT, GGGG CCCC.

Τα χαρακτηριστικά αυτά επιλέχθηκαν επειδή σχετίζονται με γνωστούς βιολογικούς μηχανισμούς δημιουργίας μεταλλάξεων, όπως η μεθυλίωση περιοχών CpG, η τοπική γονιδιωματική σταθερότητα και η παρουσία επαναλαμβανόμενων ακολουθιών.

4.3 Εξαγωγή Αναπαραστάσεων με Nucleotide Transformer

Για την αναπαράσταση των ακολουθιών DNA χρησιμοποιήθηκε το προεκπαιδευμένο μοντέλο Nucleotide Transformer. Το μοντέλο δεν επανεκπαιδεύτηκε (fine-tuning), αλλά χρησιμοποιήθηκε ως εξαγωγέας χαρακτηριστικών (feature extractor).

Κάθε μεταλλαγμένη ακολουθία μήκους 201 βάσεων δόθηκε ως είσοδος στο μοντέλο και από το τελευταίο κρυφό επίπεδο (last hidden layer) υπολογίστηκε ένα διάνυσμα αναπαράστασης 1280 διαστάσεων μέσω μέσης συγκέντρωσης (mean pooling) των ενεργοποιήσεων όλων των θέσεων της ακολουθίας.

Το παραγόμενο διάνυσμα (embedding) χρησιμοποιήθηκε ως συμπυκνωμένη αναπαράσταση της ακολουθίας DNA και αποτέλεσε την κύρια είσοδο των μοντέλων ταξινόμησης που βασίστηκαν σε foundation models.

Τέλος, δημιουργήθηκε ένα υβριδικό σύνολο χαρακτηριστικών συνενώνοντας τα 1280 χαρακτηριστικά του Nucleotide Transformer με τα βιολογικά χαρακτηριστικά του προηγούμενου σταδίου. Το σύνολο αυτό χρησιμοποιήθηκε ως είσοδος σε μοντέλο XGBoost, επιτρέποντας τον συνδυασμό πληροφορίας που προέρχεται τόσο από τις αναπαραστάσεις του foundation model όσο και από άμεσα ερμηνεύσιμα βιολογικά χαρακτηριστικά.

5 Αποτελέσματα

Στον Πίνακα 1 παρουσιάζονται τα αποτελέσματα των μοντέλων που αξιολογήθηκαν στο σύνολο ελέγχου.

Πίνακας 1: Σύγκριση μοντέλων ταξινόμησης μεταλλάξεων

Μοντέλο	MCC	ROC-AUC
Logistic Regression (k-mer Features)	0.173	0.612
1D CNN (201bp Sequence)	0.221	0.650
XGBoost focused on MUT	0.277	0.685
XGBoost (k-mer Features)	0.267	0.681
Nucleotide Transformer + XGBoost	0.270	0.692
Hybrid Model	0.313	0.722

Τα αποτελέσματα δείχνουν ότι τα παραδοσιακά μοντέλα μηχανικής μάθησης παρουσιάζουν περιορισμένη ικανότητα διάκρισης μεταξύ σωματικών και κληρονομικών μεταλλάξεων όταν χρησιμοποιούνται αποκλειστικά πληροφορίες ακολουθίας.

Η χρήση συνελκτικού νευρωνικού δικτύου (CNN) οδήγησε σε βελτίωση των αποτελεσμάτων σε σχέση με τη λογιστική παλινδρόμηση, ωστόσο η επίδοση παρέμεινε σχετικά χαμηλή.


Η αξιοποίηση αναπαραστάσεων (embeddings) από το προεκπαιδευμένο μοντέλο Nucleotide Transformer παρείχε επιπλέον βελτίωση, γεγονός που υποδεικνύει ότι το μοντέλο έχει μάθει χρήσιμες γονιδιωματικές αναπαραστάσεις από μεγάλης κλίμακας δεδομένα ακολουθιών.

Το σημαντικότερο εύρημα της εργασίας είναι ότι η ενσωμάτωση του επιπέδου συλλογιστικής (reasoning layer) μαζί με τα embeddings του Nucleotide Transformer οδήγησε στην καλύτερη συνολική επίδοση. Το υβριδικό μοντέλο πέτυχε τιμή MCC ίση με 0.313 και ROC-AUC ίσο με 0.722, παρουσιάζοντας αισθητή βελτίωση σε σχέση με το μοντέλο που βασιζόταν αποκλειστικά στα embeddings.

Το αποτέλεσμα αυτό υποδηλώνει ότι τα ερμηνεύσιμα βιολογικά χαρακτηριστικά περιέχουν συμπληρωματική πληροφορία η οποία δεν αποτυπώνεται πλήρως από τις αναπαραστάσεις του προεκπαιδευμένου μοντέλου.


5.1 Ερμηνευσιμότητα Μοντέλου

Πέρα από την αξιολόγηση της απόδοσης των μοντέλων, εξετάστηκε και η ερμηνευσιμότητα του τελικού υβριδικού μοντέλου. Για τον σκοπό αυτό χρησιμοποιήθηκαν τρεις συμπληρωματικές προσεγγίσεις: ανάλυση SHAP, ένα ερμηνεύσιμο δέντρο αποφάσεων και ανάλυση συσχέτισης μεταξύ επιλεγμένων embeddings και βιολογικών χαρακτηριστικών.




Σχήμα 2: Ανάλυση SHAP για το υβριδικό μοντέλο. Το διάγραμμα παρουσιάζει ποια χαρακτηριστικά είχαν τη μεγαλύτερη συνεισφορά στις προβλέψεις του μοντέλου.

Το διάγραμμα SHAP παρέχει μία συνολική εικόνα της συνεισφοράς των χαρακτηριστικών στις προβλέψεις του υβριδικού μοντέλου. Μέσω αυτής της ανάλυσης μπορεί να εξεταστεί αν το μοντέλο βασίζεται κυρίως στις αναπαραστάσεις του Nucleotide Transformer, στα βιολογικά χαρακτηριστικά ή σε συνδυασμό των δύο.



Σχήμα 3: Ερμηνεύσιμο δέντρο αποφάσεων βασισμένο σε επιλεγμένα embeddings και βιολογικά χαρακτηριστικά. Το δέντρο δεν χρησιμοποιήθηκε ως το τελικό μοντέλο μέγιστης απόδοσης, αλλά ως εργαλείο κατανόησης των κανόνων απόφασης.

Το ερμηνεύσιμο δέντρο αποφάσεων προσφέρει μία πιο αναγνώσιμη μορφή συλλογιστικής, καθώς παρουσιάζει την πρόβλεψη ως ακολουθία απλών διαχωρισμών. Σε αντίθεση με το XGBoost, το οποίο αποτελεί σύνολο πολλών δέντρων και είναι δυσκολότερο να παρουσιαστεί οπτικά, το συγκεκριμένο δέντρο χρησιμοποιήθηκε για να φανεί πώς μπορούν να συνδυαστούν λανθάνουσες αναπαράστάσεις και βιολογικά χαρακτηριστικά σε κανόνες απόφασης.



Σχήμα 4: Πίνακας συσχέτισης μεταξύ των Nucleotide Transformer embeddings που επιλέχθηκαν από το ερμηνεύσιμο δέντρο και των βιολογικών χαρακτηριστικών.

Ο πίνακας συσχέτισης δείχνει κατά πόσο οι διαστάσεις των embeddings που χρησιμοποιήθηκαν από το ερμηνεύσιμο δέντρο σχετίζονται με γνωστά βιολογικά χαρακτηριστικά. Θετικές τιμές υποδηλώνουν ότι η αύξηση της τιμής ενός embedding συνδέεται με αύξηση του αντίστοιχου βιολογικού χαρακτηριστικού, ενώ αρνητικές τιμές υποδηλώνουν αντίστροφη σχέση.

Η ανάλυση αυτή έδειξε ότι αρκετές διαστάσεις των embeddings σχετίζονται με χαρακτηριστικά όπως η περιεκτικότητα GC, το πλήθος CpG και η παρουσία επαναλαμβανόμενων μοτίβων. Για παράδειγμα, ορισμένα embeddings παρουσίασαν θετική συσχέτιση με GC-rich και CpG-rich περιοχές, ενώ άλλα εμφάνισαν αντίθετο πρότυπο και συσχετίστηκαν περισσότερο με AT-rich ή επαναληπτικές ακολουθίες.

Τα αποτελέσματα αυτά δεν σημαίνουν ότι κάθε διάσταση του embedding έχει μία μοναδική και πλήρως ερμηνεύσιμη βιολογική σημασία. Ωστόσο, υποδηλώνουν ότι μέρος της αναπαράστασης του Nucleotide Transformer μπορεί να συνδεθεί με βιολογικά αναγνωρίσιμα χαρακτηριστικά της ακολουθίας.

6 Συμπεράσματα

Τα αποτελέσματα έδειξαν ότι τα κλασικά μοντέλα βασισμένα σε χαρακτηριστικά k-mer, καθώς και το συνελικτικό νευρωνικό δίκτυο, μπορούν να αποδώσουν καλύτερα από μία απλή γραμμή αναφοράς, αλλά παραμένουν περιορισμένα ως προς την ικανότητα διάκρισης των δύο κατηγοριών. Η χρήση του προεκπαιδευμένου Nucleotide Transformer παρείχε βελτίωση, γεγονός που δείχνει ότι τα γονιδιωματικά foundation models μπορούν να παράγουν χρήσιμες αναπαραστάσεις για προβλήματα ταξινόμησης μεταλλάξεων.

Το υβριδικό μοντέλο, το οποίο συνδύασε τα embeddings του Nucleotide Transformer με βιολογικά ερμηνεύσιμα χαρακτηριστικά, πέτυχε την καλύτερη επίδοση μεταξύ των μοντέλων που εξετάστηκαν. Το αποτέλεσμα αυτό υποδεικνύει ότι οι λανθάνουσες αναπαραστάσεις και τα ρητά βιολογικά χαρακτηριστικά περιέχουν συμπληρωματική πληροφορία.

Ιδιαίτερο ενδιαφέρον παρουσίασε η ανάλυση ερμηνευσιμότητας. Η ανάλυση SHAP ανέδειξε ποια χαρακτηριστικά συνέβαλαν περισσότερο στις προβλέψεις, ενώ το ερμηνεύσιμο δέντρο αποφάσεων έδειξε πώς μπορούν να παρουσιαστούν οι αποφάσεις του μοντέλου σε μορφή απλών κανόνων. Επιπλέον, η συσχέτιση επιλεγμένων embeddings με βιολογικά χαρακτηριστικά έδειξε ότι ορισμένες διαστάσεις των αναπαραστάσεων σχετίζονται με έννοιες όπως η περιεκτικότητα GC, το πλήθος CpG και η επαναληπτικότητα της ακολουθίας.

Παρότι η πλήρης ερμηνεία των embeddings παραμένει δύσκολη, η εργασία δείχνει ότι ο συνδυασμός foundation models και ερμηνεύσιμων βιολογικών χαρακτηριστικών αποτελεί μία ενδιαφέρουσα προσέγγιση για την ταξινόμηση γονιδιωματικών μεταλλάξεων.

Μελλοντική εργασία θα μπορούσε να εξετάσει τη σύγκριση με άλλα γονιδιωματικά foundation models, όπως το DNABERT-2, την περαιτέρω βελτίωση της ερμηνευσιμότητας των embeddings, καθώς και την εκπαίδευση του ίδιου του προεκπαιδευμένου μοντέλου μέσω fine-tuning.

Μία επίσης ενδιαφέρουσα κατεύθυνση για μελλοντική έρευνα θα ήταν η ανάπτυξη ενός πλήρως δυναμικού πλαισίου τύπου DEFT (Dynamic Feature Generation Tree [8]) προσαρμοσμένου στην ταξινόμηση σωματικών και κληρονομικών μεταλλάξεων. Στην παρούσα εργασία χρησιμοποιήθηκαν προκαθορισμένα βιολογικά χαρακτηριστικά και αναπαραστάσεις που εξήχθησαν από το Nucleotide Transformer. Αντίθετα, ένα πραγματικό σύστημα τύπου DEFT θα μπορούσε να δημιουργεί αυτόματα νέα χαρακτηριστικά κατά την ανάπτυξη του δέντρου αποφάσεων, αναζητώντας δυναμικά μοτίβα ακολουθίας (sequence motifs) τα οποία μεγιστοποιούν την πληροφοριακή αξία κάθε διαχωρισμού.

Μία τέτοια προσέγγιση θα μπορούσε να επιτρέψει την ανακάλυψη νέων βιολογικών μοτίβων που σχετίζονται με την προέλευση των μεταλλάξεων, διατηρώντας παράλληλα υψηλό βαθμό ερμηνευσιμότητας.

Αναφορές

- [1] Dan Ofer, Nadav Brandes, and Michal Linial. The language of proteins: Nlp, machine learning & protein sequences. *Computational and Structural Biotechnology Journal*, 19:1750–1758, 2021.
- [2] Yanrong Ji, Zhihan Zhou, Han Liu, and Ramana V Davuluri. Dnabert: pre-trained bidirectional encoder representations from transformers model for dna-language in genome. *Bioinformatics*, 37(15):2112–2120, 2021.
- [3] Zhihan Zhou, Yanrong Ji, Weijian Li, Pratik Dutta, Ramana Davuluri, and Han Liu. Dnabert-2: Efficient foundation model and benchmark for multi-species genomes. In *International Conference on Learning Representations*, volume 2024, pages 41642–41665, 2024.
- [4] Hugo Dalla-Torre, Liam Gonzalez, Javier Mendoza-Revilla, Nicolas Lopez Carranza, Adam Henryk Grzywaczewski, Francesco Oteri, Christian Dallago, Evan Trop, Bernardo P De Almeida, Hassan Sirelkhatim, et al. Nucleotide transformer: building and evaluating robust foundation models for human genomics. *Nature Methods*, 22(2):287–297, 2025.
- [5] James X Sun, Yuting He, Eric Sanford, Meagan Montesion, Garrett M Frampton, Stéphane Vignot, Jean-Charles Soria, Jeffrey S Ross, Vincent A Miller, Phil J Stephens, et al. A computational approach to distinguish somatic vs. germline origin of genomic alterations from deep sequencing of cancer specimens without a matched normal. *PLoS computational biology*, 14(2):e1005965, 2018.
- [6] Gherman Novakovsky, Nick Dexter, Maxwell W Libbrecht, Wyeth W Wasserman, and Sara Mostafavi. Obtaining genetics insights from deep learning via explainable artificial intelligence. *Nature Reviews Genetics*, 24(2):125–137, 2023.
- [7] Boyan Yordanov, Sara-Jane Dunn, Colin Gravill, Hillel Kugler, and Christoph M Wintersteiger. An smt-based framework for reasoning about discrete biological models. In *International Symposium on Bioinformatics Research and Applications*, pages 114–125. Springer, 2022.
- [8] Nicolas Huynh, Krzysztof Kacprzyk, Ryan Sheridan, David Bentley, and Mihaela van der Schaar. Interpretable dna sequence classification via dynamic feature generation in decision trees, 2026.